实验三：Spark

一、 实验目的

- 学习 Spark 分布式处理框架，理解 RDD 概念
- 学习使用 spark-shell 基本命令，使用 spark 编写简单的程序

二、 任务与要求

- 学习 Spark 分布式处理框架，理解 RDD 的概念
- 学习 spark-shell 的常用指令，掌握如何进入、退出 spark-shell 以及如何提交任务
- 编写 WordCount 程序，对样例数据进行词频统计
- 编写均值方差计算程序，计算数值数据的均值与方差

三、 实验原理

3.1. Spark

Spark 是分布式批处理框架，提供分析挖掘与迭代式内存计算能力，支持多种语言（Scala/Java/Python）的应用开发。 适用以下场景：

- 数据处理（Data Processing）：可以用来快速处理数据，兼具容错性和可扩展性。
- 迭代计算（Iterative Computation）：支持迭代计算，有效应对多步的数据处理逻辑。
- 数据挖掘（Data Mining）：在海量数据基础上进行复杂的挖掘分析，可支持各种数据挖掘和机器学习算法。
- 流式处理（Streaming Processing）：支持秒级延迟的流式处理，可支持多种外部数据源。
- 查询分析（Query Analysis）：支持标准 SQL 查询分析，同时提供 DSL（DataFrame）， 并支持多种外部输入。

3.2. RDD

RDD 全名为弹性分布数据集（Resilient Distributed Dataset），它是 Spark 的核心概念，指的是一个只读，可变分区的分布式数据集，该数据集的内容可以缓存在内存中，并在多次计算中间重用。

RDD 的生成途径：

- 从 Hadoop 文件系统（或与 Hadoop 兼容的其它存储系统）输入（例如 HDFS）创建 。

- 从父 RDD 转换得到新 RDD。
- 从集合转换而来。

RDD 的存储：

- 用户可以选择不同的存储级别（例如 DISK_ONLY，MEMORY_AND_DISK）存储 RDD 以便重用。
- 当前 RDD 默认只存储于内存，当内存不足时，RDD 也不会溢出到磁盘中。

3.2. Dependency（RDD 的依赖）

父 RDD 与子 RDD 之间的逻辑关系，可分为窄依赖和宽依赖两种。

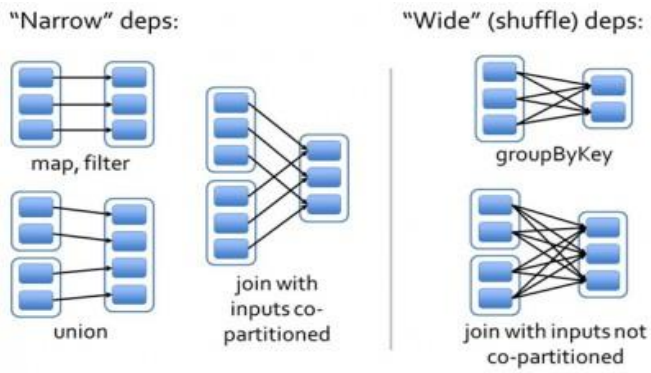

- 窄依赖：指父 RDD 的每一个分区最多被一个子 RDD 的分区所用，表现为一个父 RDD 的分区对应于一个子 RDD 的分区，或者两个父 RDD 的分区对应于一个子 RDD 的分区。上图中，map/filter 和 union 属于第一类前者，对输入进行协同划分（co-partitioned）的 join 属于第二类后者。
- 宽依赖：指子 RDD 的分区依赖于父 RDD 的所有分区，子 RDD 必须要通过 shuffle 类操作实现父 RDD 的数据全部重新分配，如上图中的 groupByKey 和未经协同划分的 join。

3.3. Transformation 和 Action（RDD 的操作）

对 RDD 的操作包含 Transformation（返回值还是一个 RDD）和 Action（返回值不是一个 RDD）两种。RDD 的操作流程如下图所示。其中 Transformation 操作是 Lazy 的，也就是说从一个 RDD 转换生成另一个 RDD 的操作不是马上执行，Spark 在遇到 Transformation 操作时只会记录需要这样的操作，并不会去执行，需要等到有 Action 操作的时候才会真正启动计算过程进行计算。Action 操作会返回结果或把 RDD 数据写到存储系统中。Action 是触发 Spark 启动计算的动因。

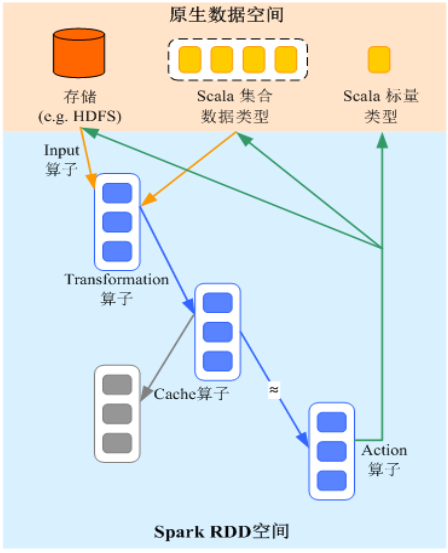

3.4. Shuffle

Shuffle 是 Spark 框架中一个特定的 phase，当 Map 的输出结果要被 Reduce 使用时，输出结果需要按 key 哈希，并且分发到每一个 Reducer 上去，这个过程就是 shuffle。由于 shuffle 涉及到了磁盘的读写和网络的传输，因此 shuffle 性能的高低直接影响到了整个程序的运行效率。

右图描述了 Shuffle 算法的整个流程。

四、 实验步骤

4.1 任务 1. 掌握 spark-shell 常用指令的使用

spark-shell 是一个强大的交互式分析数据工具，同时也是一种学习 Spark 的有效工具，它可以使用 scala 或 python 编写，本课程主要介绍 scala。

接下来学习 spark-shell 的使用。首先，登录服务器（原先的节点出了点问题，更换了新的登录节点，IP 地址会发布在群里），开启 spark-shell：

```
2018211009@thumm01:~$ spark-shell
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
Spark Context Web UI is available at Spark Master Public URL
Spark context available as 'sc' (master = spark://thumm01:7077, app id = app-20191110185959-0001).
Spark session available as 'spark'.
Welcome to
      ____              __
     / __/__  ___ _____/ /__
    _\ \/ _ \/ _ `/ __/  '_/
   /___/ .__/\_,_/_/ /_/\_\   version 2.4.4
      /_/

Using Scala version 2.12.8 (Java HotSpot(TM) 64-Bit Server VM, Java 1.8.0_221)
Type in expressions to have them evaluated.
Type :help for more information.
scala>
```

Spark-shell 除了可以使用 scala 语言操作外，还有一些基本指令，这些指令都以":"开头，指令的用法可以使用 :help 查看：

```
scala> :help
All commands can be abbreviated, e.g., :he instead of :help.
:completions <string>   output completions for the given string
:edit <id>|<line>       edit history
:help [command]         print this summary or command-specific help
:imports [name name ...] show import history, identifying sources of names
:load <path>            interpret lines in a file
:quit                   exit the interpreter
:reset [options]        reset the repl to its initial state, forgetting all session entries
:save <path>            save replayable session to a file
:sh <command line>      run a shell command (result is implicitly => List[String])
:settings <options>     update compiler options, if possible; see reset
......
```

其中几个常用的指令有：

- :quit 退出 spark-shell 控制台
- :load <path> 加载使用 scala 编写的 spark-shell 脚本
- :save <path> 将当前上下文的历史指令保存为文件

当我们在 spark-shell 中调试程序完成后，我们可以使用:save 指令将历史保存到一个文件，我们可以使用这个文件恢复之前的调试的上下文，也能将其做成一个具有一定功能的脚本。

4.2 使用 Spark 进行词频统计

接下来我们使用 spark 来做词频统计。在上一次实验中，我们使用 Java 编写 MapReduce 程序进行词频统计，那个程序如果让我们自己编写我想大部分人会不知所措。这次实验课我们使用 spark 实现词频统计的功能，只需短短几行就能实现词频统计的功能。

首先，进入在服务器命令行输入，进入 spark-shell。

```
2018211009@thumm01:~$ spark-shell
......
scala>
```

接下来，我们需要加载待统计词频的数据集。

```
scala> val textFile = sc.textFile("/wc_dataset.txt")
textFile: org.apache.spark.rdd.RDD[String] = /wc_dataset.txt MapPartitionsRDD[1] at textFile at
<console>:24
```

这句命令中，sc（Spark-Context）是 spark-shell 的上下文，这个变量是进入 spark-shell 就有的，可以用来设置一些运行参数；val textFile 是定义一个变量名为 textFile 的变量，它的值是使用 sc.textFile 函数加载 HDFS 中/wc_dataset.txt 文件的内容。

接下来可以查看这个 textFile 的内容：

```
scala> textFile.first()    #查看第一行
res0: String = chapter
scala> textFile.count()    #查看行数
res1: Long = 2683500
```

使用一行代码统计词频：

```
scala> val result = textFile.flatMap(l => l.split(" ")).map(w => (w, 1)).reduceByKey(_ + _)
result: org.apache.spark.rdd.RDD[(String, Int)] = ShuffledRDD[4] at reduceByKey at <console>:25
scala> result.first()    #查看结果的第一行内容
res3: (String, Int) = (someone,100)
scala> result.saveAsTextFile("wc_output")
```

接下来我们来解释这行代码，代码的流程如下图所示：

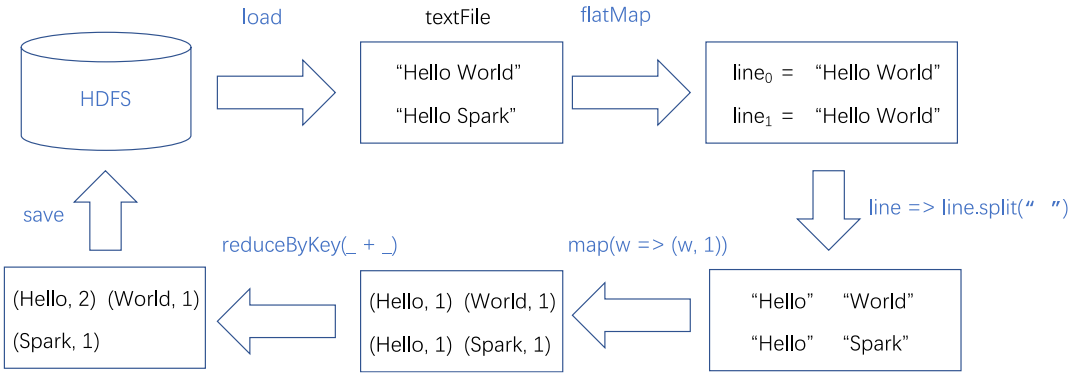

- 从 HDFS 中加载文件 wc_dataset.txt， 保存内容到变量 textFile
- 对 textFile 逐行处理，对每一行按空格进行分割，得到一个字符串列表
- 使用 map 将字符串列表转成一个键值对列表[<key1, value1>, <key2, value2>, ……],其中键为单词，值为词频（没有合并之前为 1）。
- 将不同的键值对根据相同的键不断地合并，直至无法合并，得到词频统计结果。
- 将结果保存到 HDFS 中(保存到了/user/学号/wc_output)。

使用:quit 指令退出 spark-shell，然后将结果复制到本地：

```
scala> :quit
2018211009@thumm01:~$ hadoop fs -get wc_output ./
2018211009@thumm01:~$ cd wc_output/
2018211009@thumm01:~/wc_output$ ls
_SUCCESS  part-00000  part-00001
2018211009@thumm01:~/wc_output$ head -n 5 part-00000
(someone,100)
(bone,100)
(doubtfully,200)
(order,300)
(spirited,100)
```

4.3 使用 Spark 计算均值与方差

第二次 MapReduce 实验要求大家实现自己的 MapReduce 框架，然后使用自己的框架来计算均值与方差，接下来我们使用 Spark 来实现这个功能。

首先，创建一个数据集(1 到 1000,000)：

```
2018211009@thumm01:~$ for ((i=1; i<=1000000; i=i+1)); do echo $i >> numbers.txt; done
2018211009@thumm01:~$ tail -n 3 numbers.txt
999998
999999
1000000
```

这个数据集的均值为 500000.5，方差为 288675.1345946685

接着将这个数据集上传到 HDFS:

```
2018211009@thumm01:~$ hadoop fs -put numbers.txt
2018211009@thumm01:~$ hadoop fs -tail numbers.txt
……
999999
1000000
```

运行 spark-shell，从 HDFS 加载 number.txt：

```
scala> val numbers = sc.textFile("numbers.txt")
numbers: org.apache.spark.rdd.RDD[String] = numbers.txt MapPartitionsRDD[1] at textFile at <console>:24
```

加载的数据为字符串形式，需要转成数值型，这里转 double 型

```
scala> val numbers_double = numbers.map(num => num.toDouble)
numbers_double: org.apache.spark.rdd.RDD[Double] = MapPartitionsRDD[2] at map at <console>:25
```

统计数字个数

```
scala> val n_num = numbers_double.count()
n_num: Long = 1000000
```

计算均值

```
scala> val mean = numbers_double.reduce(_ + _) / n_num
mean: Double = 500000.5
```

计算方差

```
scala> val variance = numbers_double.map(num => num - mean).map(num => num*num).reduce(_ + _) / n_num
variance: Double = 8.333333333359143E10
```

计算标准差

```
scala> import scala.math._    #导入 scala 数学库
import scala.math._


scala> val std = sqrt(variance)
std: Double = 288675.1345952599
```

五、 作业提交要求

- 在词频统计任务中，要求大家：
  - 使用自己的数据集，并将结果下载到本地合并，贴出词频最高的 10 个单词的统计结果。
  - 换用另一种 RDD 函数组合实现 WordCount 功能（越多越好，bonus！），测试不同实现方式的所用的时间。
- 将以上作业所用到的数据、命令、步骤截图等写入实验报告，然后连同所有代码文件一同打包成压缩文件，上交至网络学堂。
- 迟交作业一周以内，以 50%比例计分；一周以上不再计分。另一经发现抄袭情况，零分处理。
- 助教联系方式：严浩鹏（yhp18@mails.tsinghua.edu.cn）